

Computer Vision EXAM

The exam can be taken in one of two ways:

1. by taking a **written** exam on the topics covered during the course. This method follows the scheduled exam dates.
2. by completing a **project** according to the methods outlined below.

In both cases registering for an exam session is necessary to record the grade.

Project modalities

The projects are intended as **challenges** and are meant for students who wish to explore the topic in greater depth (possibly also with a view toward a thesis). Projects that simply apply standard architectures covered during the course are not allowed.

- The project deadline is independent of the scheduled dates for the oral exams. If you decide to take the exam through a project, please contact the professor to agree on the project topic.
- The project must be submitted within one year from the date of assignment. After this period, please contact the professor to update the proposal.
- The project can be carried out by one or two students. In the latter case, a deeper analysis and more extensive investigation are expected (e.g., comparing different techniques).

Students choosing this option are required to produce:


- **Working code**, including adequate experimentation and analysis (an explanation of the code and a demo will be required during the presentation).
- **A written report** that frames the context, formally introduces the background and the proposed methodology, presents the experimental results, and discusses their analysis. The report may be written in either Italian or English.

Finally, the project must be presented approximately one week after submitting the code and the report, with a presentation of about 20 minutes (slides may be used if desired) + 10 minutes for questions. During the presentation, students are expected to introduce the new topic studied and place it within the context of the material covered in the lectures.

Below are some possible project proposals. If all the projects are assigned, the professor will propose additional topics.

Proposal #1: Mapping Cardiac Anatomy Through The Lens Of Vision

- **GOAL:** Inferring 3D Trajectories from 12-leads ECG signals.
- **IDEA:** Standard 12-lead ECGs decompose cardiac activity along non-orthogonal, redundant axes, making them geometrically easy and difficult to visualize.
- **APPLICATION DOMAIN:** Medical AI, Computer Vision, Biomedical Signal Processing.
- **SOURCES:** <https://github.com/FMMGroupVa>



Descrizione Dettagliata

Mapping Cardiac Anatomy through the lens of vision: inferring 3D Trajectories of the electric heart vector (EHV) from 12-leads ECG signals.

L'elettrocardiogramma a 12 derivazioni (ECG) costituisce lo strumento clinico di riferimento per la valutazione dell'attività elettrica del miocardio. Esso decompone tale attività lungo 12 assi di proiezione non necessariamente ortogonali tra loro, alcuni dei quali linearmente dipendenti. Questa ridondanza e mancanza di ortogonalità rendono la rappresentazione ECG geometricamente scomoda: difficile da visualizzare in uno spazio tridimensionale e inadatta come input diretto a modelli di deep learning che operano nello spazio euclideo 3D e che cercano di preservare la geometria dell'input modellando trasformazioni fisicamente eseguibili e geometricamente interpretabili.

L'obiettivo del progetto è il seguente: indagare i metodi che permettono di convertire il segnale ECG a 12 derivazioni in una rappresentazione 3D della dinamica cardiaca del vettore impulso elettrico del miocardio.

Tra le rappresentazioni tridimensionali della dinamica cardiaca estraibili dall'ECG a 12 derivazioni, la più consolidata in letteratura è la **Vettorcardiografia (VCG)**: una rappresentazione del vettore dipolo elettrico del cuore — detto **Electric Heart Vector (EHV)** — nelle tre direzioni ortogonali dello spazio (X, Y, Z), tipicamente acquisita tramite il sistema di lead di Frank a 7 elettrodi. Il VCG esprime in forma geometrica diretta la stessa informazione fisica frammentata nelle 12 proiezioni scalari dell'ECG, rendendo esplicita la traiettoria tridimensionale dell'EHV nel tempo sotto forma di loop chiusi — le cui forma, orientazione e ampiezza costituiscono marker diagnostici riconosciuti.

Il presente progetto ha come scopo:

- (progetto) studiare e applicare metodi presenti in letteratura per ricostruire, a partire dall'ECG a 12 derivazioni, una rappresentazione tridimensionale della dinamica temporale dell'Electric Heart Vector (EHV) in esso implicitamente codificato.
- (Progetto + tesi) addestrare, tramite apprendimento supervisionato, un modello deep learning per l'individuazione di patologie cardiache a partire dalle rappresentazioni 3D della traiettoria dell'EHV così ricostruite.

Requisiti del progetto:

1. Studio delle metodologie di estrazione 3D da ECG a 12 derivazioni: Il progetto richiede la conoscenza approfondita di almeno due metodologie per l'estrazione di informazione tridimensionale dall'ECG a 12 derivazioni. La metodologia **3D-FMM-ECG** è obbligatoria; le restanti sono a scelta tra quelle elencate di seguito.

- **Metodologia obbligatoria: 3D-FMM-ECG (3D Frequency Modulated Möbius Electrocardiogram, Rueda et al., 2022)**. Il modello assume che il campo elettrico cardiaco origini da un sistema a dipoli multipli, uno per ciascuna delle cinque onde fondamentali del battito (P, Q, R, S, T). Diversamente dal VCG classico, che fornisce un'unica traiettoria 3D integrata sull'intero ciclo cardiaco, il modello 3D-FMM-ECG decompone analiticamente il segnale nelle cinque componenti d'onda, restituendo cinque traiettorie 3D distinte, una per ciascuna onda, insieme a parametri scalari interpretabili (ampiezza, fase, asimmetria) per ogni onda e ogni lead. Il codice di riferimento è disponibile al repository ufficiale del gruppo (github.com/FMMGroupVa), nei progetti FMM-Applications-3DECG e FMM-base-R-package. Poiché l'implementazione è in R, il progetto richiede o un porting completo in Python oppure l'integrazione tramite la libreria rpy2 per chiamare codice R da un ambiente Python.
- Metodologie a scelta (almeno una):
 - Inverse Dower Transform: Dower derivò originariamente una matrice di trasformazione C per sintetizzare l'ECG a partire dal VCG, fondandosi su un modello a dipolo e sulla geometria del torace. Tramite la pseudoinversa di Moore-Penrose è possibile ottenere un'approssimazione dell'inversa di C, nota come Inverse Dower Transform matrix, che permette di ricavare il VCG dall'ECG a 12 derivazioni.
 - Kors Regression. Regressione lineare multivariata stimata empiricamente su un campione di pazienti per cui erano disponibili sia ECG a 12 derivazioni che VCG di Frank. Produce una matrice di trasformazione che mappa gli 8 lead indipendenti dell'ECG nelle tre derivazioni ortogonali X, Y, Z.
 - Trasformazione Bayesiana. Approccio probabilistico che modella l'incertezza nella stima del VCG a partire dall'ECG, incorporando prior sulla distribuzione dei parametri cardiaci.
 - Trasformazione Affine. Classe generale di trasformazioni lineari che include traslazione, rotazione e scaling; utilizzata come approssimazione della relazione geometrica tra il sistema di lead ECG e il sistema di Frank.

2. Applicazione e validazione su dataset: le metodologie selezionate andranno applicate al Dataset 1 (descritto nella sezione successiva, "Requisiti per la tesi"). I VCG estratti tramite ciascun metodo saranno confrontati con i VCG ground truth presenti nel dataset, al fine di valutare quantitativamente la fedeltà geometrica della ricostruzione.

Requisiti per la tesi (oltre a quelli per il progetto):

3. Identificazione del task di classificazione: Il candidato dovrà scegliere un task di classificazione di patologie cardiache e il relativo dataset tra quelli proposti di seguito.

La scelta determinerà il focus clinico e metodologico della tesi:

1. Dataset 1 (PTB Diagnostic ECG Database (PTBDB), Task: Ischemica e Infarto del Miocardio (MI)): Il database contiene 549 registrazioni provenienti da 289 pazienti. Un sottoinsieme ampiamente utilizzato in letteratura comprende circa 347–368 pazienti con infarto del miocardio e 80 soggetti sani (HC). Ogni registrazione include 15 segnali misurati simultaneamente: le 12 derivazioni ECG standard più le 3 derivazioni ortogonali del sistema di Frank (X, Y, Z), che costituiscono il VCG ground truth. Questa caratteristica rende PTBDB il dataset ideale per valutare quantitativamente la discrepanza tra i VCG ricostruiti con i metodi studiati e i VCG reali. È pertanto la scelta raccomandata qualora il progetto si concentri esclusivamente sulla comparazione tra

VCG stimato e VCG ground truth.

2. Dataset 2 (PTB-XL Database), Task: Ipertrufie, Cardiomiopatie e Anomaly Detection

Generica: Il database contiene 21.837 registrazioni ECG a 12 derivazioni della durata di 10 secondi, provenienti da 18.885 pazienti, etichettate secondo l'ontologia SNOMED CT. Le etichette sono organizzate in 5 macro-superclassi, Normale (NORM), Infarto del Miocardio (MI), Alterazioni ST/T (STTC), Disturbi di Conduzione (CD) e Ipertrufia (HYP).

3. Dataset 3 (MIT-BIH Arrhythmia Database), Task: Difetti di Conduzione (Blocchi di Branca) e Aritmie:

Database clinico di riferimento (benchmark) per la ricerca sul riconoscimento automatico di battiti anomali e aritmie. Le classi di interesse principali sono: NORMAL (battito sano), PVC (contrazione ventricolare prematura), APC (battito prematuro atriale), RBBB (blocco di branca destra), PACE (battito stimolato da pacemaker) e NOISY (segmenti fortemente disturbati da artefatti).

4. Identificato il task, l'obiettivo centrale della tesi consisterà nel **valutare la capacità diagnostica delle rappresentazioni 3D dell'attività elettrica cardiaca, ovvero delle traiettorie tridimensionali dell'EHV estratte con i metodi studiati**, per la predizione delle anomalie del task scelto. A tal fine, il candidato dovrà mappare la rappresentazione 3D verso una stima della classe di patologia/non-patologia di appartenenza, attraverso un metodo di signal processing o un modello ML/Deep Learning (selezionato dalla letteratura oppure progettato e addestrato autonomamente) e valutarne le prestazioni tramite metriche standard (accuratezza, F1-score, AUC-ROC, etc.). L'analisi dovrà in particolare confrontare:

- * la capacità del modello di generalizzare su dati non visti

- * la capacità della rappresentazione 3D di servire come spazio di feature informativo per il task, rispetto ad approcci che operano direttamente sull'ECG grezzo a 12 derivazioni

Tra i metodi presenti in letteratura, le risorse A, B e C in bibliografia illustrano tre approcci metodologici non-deep di riferimento.

Bibliografia:

[VCG review, metodi di estrazione da 1 a 4]

<https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2022.856590/pdf>

[modello 3D-FMM-ECG]

https://www.researchgate.net/profile/Cristina-Rueda-3/publication/365640590_A_Unique_Cardiac_Electrocardiographic_3D_Model_Towards_Interpretable_AI_Diagnosis/links/638d9d687d9b40514e171e08/A-Unique-Cardiac-Electrocardiographic-3D-Model-Towards-Interpretable-AI-Diagnosis.pdf

[A: VCG per infarto del MI utilizzando tecnica ML]

<https://link.springer.com/article/10.1007/s11760-017-1068-9>

[B: VCG per infarto del MI utilizzando tecnica ML]


<https://link.springer.com/article/10.1007/s11760-017-1146-z>

[C: VCG per infarto del MI utilizzando tecnica ML]

<https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2025.1683956/pdf>

Proposal #2: EEG-based Neural Flows In Python

- **GOAL:** Implement a complete Python pipeline to estimate cortical vector fields (known as 'spatiotemporal wave patterns' or 'phase flow fields') from N-channel EEG input data.
- **IDEA:** Reconstruct brain electrical activity as a continuous vector field on the scalp surface by solving an EEG inverse problem.
- **APPLICATION DOMAIN:** Medical AI, Computer Vision, Biomedical Signal Processing.
- **SOURCES:** <https://brain-modelling-group.github.io/publication/roberts-2019-metastable/>



Descrizione Dettagliata

Obiettivo del progetto è l'implementazione in python di un algoritmo che, dato in ingresso un tracciato EEG a N canali, stimi, attraverso metodi alle derivate parziali, il campo vettoriale denominato 'spatiotemporal wave patterns' (o 'phase flow field') catturato indirettamente dagli N elettrodi disponibili nel tempo.

Più precisamente, il segnale EEG (elettroencefalogramma) misura i potenziali elettrici sulla superficie del cuoio capelluto. A partire da un tracciato EEG è possibile risalire al campo vettoriale definito su una griglia corticale continua mediante risoluzione del "problema inverso" derivato dall'analisi spaziale e temporale delle fasi dei segnali EEG, stimando localmente la velocità e direzione del flusso di fase (phase flow) compatibilmente con modelli di onde cerebrali.

Nel paper (1), dopo aver presentato in breve (sezione 5.2) i passaggi per il calcolo del suddetto campo vettoriale per il task di upsampling di dati EEG (task che a noi interessa solo in modo marginale), vengono presentate (Appendice A), le fasi di (A.1) pre-processing, (A.2) calcolo delle wave velocities, (A.3) metodo per l'interpolazione sferica dei canali EEG in ingresso (ancora pre-processing) e l'interpolazione lineare del campo vettoriale in uscita (post-processing), (A.4) eventuali tecniche di feature extraction per determinare quali aree siano più rilevanti per successivi task (GitHub1:<https://github.com/Dynamics-of-Neural-Systems-Lab/RVGP.git>).

Nonostante il paper descriva questi steps, il codice relativo alla parte di estrazione di vector fields da EEG non è presente nel GitHub di riferimento, ma, al contrario, è demandata all'implementazione in Matlab descritta nel paper (2), GitHub2:<https://github.com/brain-modelling-group/brainwaves.git> (per la simulazione di "metastable waves") e nel paper (3), GitHub3:<https://github.com/brain-modelling-group/neural-flows.git> (effettivo codice per l'estrazione di vector fields da dati EEG/MEG reali).

Il cuore del codice 'neural flows' è il modulo "Constrained Natural Element Method" (CNEM), metodo per risolvere equazioni alle derivate parziali (PDEs), spiegato nel dettaglio nel paper (4).

Passaggi principali per lo svolgimento del progetto:

Neuroscientific/physical background: Acquisire e padroneggiare i fondamenti teorici che permettono di rappresentare l'attività cerebrale come un campo vettoriale definito su una superficie non euclidea. Approfondire la letteratura di riferimento (i paper indicati e ulteriori rimandi pertinenti), con particolare attenzione al problema inverso legato alla ricostruzione di campi corticali a partire dai potenziali EEG. Un valido punto di partenza, soprattutto per comprendere gli aspetti matematici e fisici del problema, è rappresentato dalla seguente serie di video-lezioni (https://www.youtube.com/playlist?list=PLp67eqWCj2f_DBsCMkIOBpBbLWGauKtu5).

Work-flow definition: rappresentare in modo schematico e grafico l'intera pipeline di elaborazione, articolata in blocchi funzionali che descrivano il flusso completo dall'input EEG fino all'output costituito dai campi vettoriali definiti sulla manifold corticale. Seguire le linee guida metodologiche dei paper di riferimento e analizzare i codici esistenti per individuare con chiarezza quali componenti debbano essere implementate ex novo e quali possano essere riutilizzate o adattate da soluzioni già disponibili.

Implementation: sviluppare l'intera pipeline in Python, effettuando il porting da MATLAB ove possibile e integrando le componenti mancanti tramite codice scritto ex novo. Eseguire quindi la pipeline su un campione di dati EEG fornito (Dataset: [specificare dataset di riferimento]), verificando qualitativamente la corretta generazione dei campi vettoriali spaziotemporali in uscita.

Bibliografia:

(1): <https://arxiv.org/pdf/2309.16746>

(2): <https://www.nature.com/articles/s41467-019-08999-0.pdf>


(3): <https://www.nature.com/articles/nn1802>

(4):

https://www.sciencedirect.com/science/article/pii/S0045794911000307?casa_token=4yVqtOxwrNMAAAA:A:YdbbBxpsNrUjkMi26yieJyT1C12b-M-qHnQgf-Nr-GcEhTKpycJu_7sScU4t6Filw72qsbLRIKc

Proposal #3: Geometry-Grounded Alzheimer's Detection from EEG

- **GOAL:** Classify EEG traces into three clinical classes (Cognitively Normal, Alzheimer's Disease, and Frontotemporal Dementia) using advanced Geometric Deep Learning architectures.
- **IDEA:** Apply Gyrovector space Graph Neural Networks to causal connectivity graphs extracted via PCMCI, Granger, or LiNGAM.
- **APPLICATION DOMAIN:** Medical AI, Computer Vision, Biomedical Signal Processing.
- **SOURCES:** <https://github.com/HazyResearch/hgcn> , <https://github.com/fightlesliefigt/HEEGNet>



Descrizione dettagliata

L'elettroencefalogramma (EEG) è uno strumento clinico non invasivo fondamentale per lo studio delle alterazioni dell'attività cerebrale causate da disordini neurodegenerativi come la Malattia di Alzheimer (AD) e la Demenza Frontotemporale (FTD). Tali patologie provocano un'alterazione delle dinamiche oscillatorie e una progressiva disconnessione o atrofia nelle reti di comunicazione tra le diverse aree del cervello. Tradizionalmente, la classificazione tramite deep learning su dati EEG si basa su architetture "black-box" che non riescono a catturare appieno la natura geometrica (struttura gerarchica della connettività) del cervello.

L'obiettivo del progetto è il seguente: indagare l'utilizzo di modelli avanzati basati su reti in spazi non-euclidei per predire le classi Normale (CN), Alzheimer (AD) e Demenza Frontotemporale (FTD). In particolare sarà necessario:

- * Studiare ed estrarre le reti di connettività effettiva (ECN) dai segnali EEG utilizzando metodi di inferenza causale (PCMCI, Granger o LiNGAM) applicato al segnale EEG in ingresso, per un numero di lag stabilito.
- * Addestrare e validare un modello Hyperbolic GNN basato su Girovettori (<https://github.com/HazyResearch/hgcn>) per la classificazione delle tre classi.

Requisiti del progetto:

1. Mathematical Background: Approfondire la letteratura di riferimento per comprendere da un lato l'estrazione di relazioni causali da serie storiche, e dall'altro l'impiego della geometria iperbolica (modello di Lorentz e spazi di Girovettori) per il deep learning. Alcune risorse utili per la parte geometrica: <https://andbloch.github.io/K-Stereographic-Model/>, <https://www.youtube.com/watch?v=TMZmXT5IOsY>.
2. Dataset: Il progetto richiede il training e la validazione del modello Hyperbolic GNN su un dataset pubblico di riferimento contenente registrazioni EEG a 19 canali (sistema 10-20) (<https://openneuro.org/datasets/ds004504/versions/1.0.7>).

Bibliografia:

[Gyrovectors NN review] : <https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=96582224>

[Gyrovector GNN] : <https://arxiv.org/pdf/1910.12933>

[Gyrovectors for EEG on Matrix Manifold] : <https://arxiv.org/pdf/2601.03322>

[ECoGNet, Rete a grafo classica su pre-processing causale]:


https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=11228047&casa_token=9gL0GQx79CMAAAAA:1D05fVKc1vGfMHCopZMgohvKJhCaDnTTMn3MCbEWuk8U2qLC9QuJR4mzLZbAbWLwx-9Dtk8dDIKTtC4&tag=1

[PCMCI]: <https://www.science.org/doi/pdf/10.1126/sciadv.aau4996#page=1.00&gsr=0> [Granger]:
<http://www.econ.uiuc.edu/~econ536/Papers/granger69.pdf>

[Lingam]: <https://link.springer.com/content/pdf/10.2333/bhmk.41.65.pdf>

Proposal #4: Physics-Grounded EEG Deep Understanding

- **GOAL:** Design EEG-based BCI for Visual Evoked Potential or Emotion Recognition application using Stochastic Neural SDE architectures.
- **IDEA:** Apply Stochastic Neural SDEs networks on raw EEG signals.
- **APPLICATION DOMAIN:** Medical AI, Computer Vision, Biomedical Signal Processing.
- **SOURCES:** <https://github.com/yongkyung-oh/Stable-Neural-SDEs>



Descrizione dettagliata

L'elettroencefalogramma (EEG) rappresenta uno strumento non invasivo di riferimento per l'acquisizione dell'attività elettrica cerebrale in tempo reale, trovando applicazione in due domini di crescente rilevanza clinica e tecnologica: il riconoscimento di Potenziali Evocati Visivi (Visual Evoked Potentials, VEP) e il riconoscimento delle emozioni (Emotion Recognition). Entrambi i task condividono una sfida fondamentale: l'attività EEG è intrinsecamente un processo stocastico e non stazionario, la cui dinamica temporale continua non è adeguatamente catturata dalle architetture deep learning convenzionali, che trattano il segnale come una sequenza discreta e ne ignorano la natura differenziale sottostante.

Le architetture black-box tradizionali apprendono rappresentazioni statistiche del segnale senza incorporare alcun prior sulla sua fisica: non modellano esplicitamente la continuità temporale, l'incertezza stocastica intrinseca del processo neurale.

L'obiettivo del presente progetto è progettare un sistema BCI (Brain-Computer Interface) basato su EEG per task di riconoscimento VEP o emotivo, adottando come backbone architetturale le **Stochastic Neural Differential Equations (Neural SDEs)**, modelli che trattano la dinamica cerebrale come un processo differenziale stocastico continuo nel tempo, governato da una deriva deterministica e una componente di diffusione apprendibile. Questo approccio consente di modellare esplicitamente l'evoluzione continua del segnale EEG e la sua incertezza intrinseca, offrendo al contempo maggiore interpretabilità rispetto ai modelli black-box standard. In particolare sarà necessario: addestrare e validare un modello di deep learning basato su Neural Stochastic Differential Equations (Neural SDEs: <https://github.com/yongkyung-oh/Stable-Neural-SDEs>) per i task 'visual' e/o 'emotion' previsti e discussi nel paper (B).

Requisiti del progetto:

1. Mathematical Background: Approfondire la letteratura di riferimento per comprendere l'impiego di equazioni differenziali stocastiche per il deep learning (paper (A)). Alcune risorse utili per la parte SDEs: https://betanalpha.github.io/assets/case_studies/stochastic_differential_equations.html.
2. Dataset: Il progetto richiede utilizzo di uno o più DB riportati nella sezione sperimentale del paper (B).


Bibliografia:

[(A) Neural SDEs] : <https://arxiv.org/pdf/2402.14989>

[(B) Uno dei metodi più recenti in ambito BCI da EEG]: <https://arxiv.org/pdf/2601.03322>

Proposal #5: 3D Dental Kinematics

- **GOAL:** Develop an automated pipeline for the objective assessment of tooth movement during aligner treatment by estimating the actual 3D roto-translation of each tooth between successive time points.
- **IDEA:**
 - Automatic tooth segmentation from intraoral scans using a deep learning model (e.g., datasets/models from the 3DTeethSeg Challenge).
 - Rigid registration (ICP) + non-rigid registration (NRICP).
 - Extraction of the deformation field for each crown.
 - Rigid fitting (Kabsch algorithm) → 3D translation + rotation per tooth.
 - Output: quantitative measurement of actual tooth movement.
- **APPLICATION DOMAIN:** Digital orthodontics, aligner performance evaluation, planned vs. actual tooth movement comparison, clinical decision support
- **SOURCES:** <https://www.mdpi.com/2673-6373/4/4/39>
<https://www.sciencedirect.com/science/article/pii/S0020653925002370>
<https://github.com/nnistelrooij/3dteethland>



Detailed description

1. Background and Rationale

Assessment of orthodontic treatment outcomes with clear aligners is still largely **subjective**, relying on clinical observation or visual comparison of intraoral scans.

Research methods exist to estimate the 3D movement of teeth using:

- Tooth crown segmentation
- Rigid and non-rigid registration between successive scans
- Rigid fitting of each crown to calculate roto-translations

However, these methods often require **manual intervention**. This project aims to **fully automate the pipeline**, enabling objective and quantitative measurement of actual tooth movement.

2. Goal

Develop an automated pipeline for the **objective evaluation of tooth movement** during aligner treatment, estimating the **actual 3D roto-translation of each tooth** across successive intraoral scans.

3. Methodology

Step 1 – Tooth Segmentation

- Apply pretrained deep learning models (e.g., datasets/models from the **3DTeethSeg Challenge**) to automatically segment individual teeth from 3D intraoral scans.

Step 2 – Pre-processing

- Trim and clean the mesh at the mucogingival junction

- Fuse segmented crowns into a single mesh
- Remove artifacts

Step 3 – Registration

1. **Rigid Registration (ICP)** – global alignment between scans
2. **Non-Rigid Registration (NRICP)** – compute local deformations for each tooth

Step 4 – Tooth Motion Extraction

- Isolate the deformation field for each crown
- Perform rigid fitting using the **Kabsch algorithm** to estimate:
 - 3D translation
 - 3D rotation

Step 5 – Metrics and Output

- Quantitative measurement of actual tooth movement per tooth
- Comparison with planned movement (if available)
- Aggregate statistics and graphical visualization of movement vectors

4. Expected Outcomes


- Fully automated pipeline for evaluating tooth movements
- Objective and reproducible measurement of treatment outcomes
- Potential applications:
 - Optimize refinement strategies
 - Detect teeth with anomalous movement
 - Support clinical decision-making with quantitative data

5. Application Domains

- Digital orthodontics
- Aligner performance evaluation
- Clinical decision support
- Dental biomechanics research
- treatment optimization

Proposal #6: Hierarchical Masked Autoencoders Discover Resolution-Specific Structure in EEG

- **GOAL:** Develop an automated framework to analyze EEG signals using hierarchical self-supervised learning, identifying which **temporal scales** carry predictive information for clinical or cognitive outcomes.
- **IDEA:**
 - Apply a hierarchical masked autoencoder approach (inspired by **HiMAE**) to EEG time series.
 - Learn multi-resolution temporal embeddings from raw EEG.
 - Systematically probe predictive performance across temporal scales.
 - Compare scale-specific representations for classification/regression tasks.
 - Output: quantitative identification of informative temporal resolutions in EEG.
- **APPLICATION DOMAIN:** Computational neuroscience, clinical EEG analysis, biomarker discovery, edge AI for wearable / portable EEG systems
- **SOURCES:** <https://arxiv.org/pdf/2510.25785>



Detailed description

1. Background and Rationale

Electroencephalography (EEG) provides rich multivariate time-series data reflecting neural dynamics across multiple temporal scales. However, it remains unclear which temporal resolutions are most informative for specific clinical or cognitive outcomes.

Recent work such as **HiMAE (Hierarchical Masked Autoencoder)** proposes that *temporal resolution is not just a hyperparameter, but a meaningful axis of representation learning*. Different tasks may rely on structure encoded at distinct time scales (e.g., milliseconds vs seconds).

This project aims to transfer and adapt this resolution-aware self-supervised learning framework to EEG data.

2. Goal

Develop a hierarchical self-supervised learning framework for EEG that:

- Learns **multi-resolution temporal embeddings** directly from raw signals
- Identifies which temporal scales carry predictive information
- Improves interpretability by linking performance to signal resolution

3. Methodology

Step 1 – Data

Use resting-state or task-based EEG datasets (e.g., clinical classification or cognitive state prediction).

Step 2 – Self-Supervised Pretraining

Implement a hierarchical masked autoencoder architecture inspired by HiMAE:

- Mask portions of EEG time series
- Train a convolutional encoder–decoder to reconstruct missing segments
- Extract latent embeddings at multiple temporal resolutions

This enables learning scale-aware representations without supervision.

Step 3 – Resolution Probing

For each temporal scale:

- Freeze the encoder
- Train lightweight downstream models (classification or regression)
- Evaluate predictive performance per resolution

This transforms temporal scale into an interpretability probe rather than a tuning parameter.

Step 4 – Comparative Evaluation

Compare:

- Single-scale representations
- Multi-scale embeddings
- Standard EEG feature-based pipelines

4. Expected Outcomes

- Identification of task-relevant temporal scales in EEG
- More interpretable representation learning
- Improved performance over traditional approaches
- A lightweight model potentially suitable for edge deployment

5. Application Domains


- Clinical EEG analysis (e.g., neurodegeneration, stress, cognitive state)
- Biomarker discovery
- Brain–computer interfaces
- Edge AI for portable or wearable EEG devices

Proposal#7: Conformal Equivariant Point Cloud Classification via Superquadrics

- **GOAL:** Develop a 3D classification framework that is **conformally equivariant** (robust to rotation, translation, isotropic scaling, and spherical inversion) by representing raw point clouds through a set of geometric **superquadric primitives**.
- **IDEA:**
 - **Superquadric Decomposition:** Use a model inspired by **PartGS** to decompose complex point clouds into a compact set of superquadrics (superellipsoids, supertoroids).
 - **CGA Embedding:** Map the extracted superquadric parameters (position, orientation, and shape) into **Conformal Geometric Algebra (CGA)** elements.
 - **Equivariant Backbone:** Process these primitives through a neural network with **conformal equivariant layers** to ensure classification remains consistent across all conformal transformations.
 - **Dimensionality Reduction:** Transition from processing thousands of unorganized points to a few dozen structured primitives while preserving global topology.
- **WHY?:**
 - **Native Scale Invariance:** Unlike standard Euclidean models, this approach handles objects at any scale without requiring extensive data augmentation.
 - **Structural Efficiency:** Classifying based on primitives (superquadrics) is computationally lighter and more interpretable than raw point-based architectures like PointNet.
 - **Mathematical Rigor:** Leveraging **Conformal Equivariant Networks** ensures that the model's internal features "rotate and scale" predictably with the input data.
- **SOURCES:**
 - [Conformal Equivariant Networks \(arXiv:2505.12880\)](#).
 - <https://arxiv.org/pdf/2408.10789>



translations





rotations



scalings


Proposal#8: Landmarks 3D

- **GOAL:** Develop a high-precision 3D landmark prediction pipeline that leverages semantic foundation models (**PartField**) and differentiable rendering (**Gaussian Splatting**) to achieve state-of-the-art anatomical or structural localization on 3D meshes.
- **IDEA:**
 - **Foundation Feature Extraction:** Utilize **NVIDIA's PartField** to generate a dense, semantic feature field from the input 3D data, capturing fine-grained part-level information.
 - **Gaussian Field Mapping:** Map the PartField latent features onto the mesh surface using **3D Gaussian Splatting**. This creates a continuous, high-fidelity semantic "texture" across the geometry.
 - **Graph-Based Processing:** Input the feature-rich mesh into a **2S-SGCN (Two-Stream Spatial Graph Convolutional Network)**. The two-stream architecture allows for simultaneous processing of:
 - **Vertex Coordinates** (Spatial/Geometric stream).
 - **PartField Embeddings** (Semantic/Feature stream).
 - **Landmark Regression:** The network predicts heatmaps or direct coordinates for specific landmarks by fusing geometric topology with foundation-model semantics.
- **SOURCES:**
 - <https://www.sciencedirect.com/science/article/pii/S107731422400>,
 - <https://arxiv.org/pdf/2402.01459>
 - <https://arxiv.org/pdf/2504.11451>
 - <https://arxiv.org/abs/2511.18386>



Proposal#9: 3D-Language Gaussian Field at any Granularity


- **GOAL:** Build a 3D Visual Question Answering (VQA) system that can reason about complex environments at any level of detail, overcoming the "fixed-object" bottleneck of current 3D semantic models.
- **IDEA:** Integrate **Continuous Granularity Segmentation** into the **Gaussian Splatting** pipeline to enable query-adaptive 3D reasoning:
 - **Feature Integration (UnSAMv2):** Replace static 2D masks with *UnSAMv2* embeddings. This allows the system to represent the scene as a continuous hierarchy—from global architecture down to micro-textures—without predefined segmentation boundaries.
 - **Semantic Gaussian Fusion:** Lift these multi-scale 2D features into 3D space. Each Gaussian point stores a "granularity-aware" latent vector, allowing the model to "group" points dynamically based on the required scale.
 - **Dynamic 3D Reasoning (SplatTalk):** Power the VQA engine with *SplatTalk*. When a user asks a question, the system uses the UnSAMv2 backbone to "zoom in" or "zoom out" its semantic focus.
 - *Broad Query:* "How many chairs are in the room?" → High-level grouping.
 - *Specific Query:* "Is there a scratch on the left leg of the third chair?" → Micro-scale grouping.
- **SOURCES:**
 - <https://arxiv.org/pdf/2503.06271>
 - <https://arxiv.org/pdf/2511.13714>




Proposal#10: Zero-Shot Object Mask Matching between Ego Exo Views

- **GOAL:** Achieve precise **Zero-Shot Object Correspondence** between Egocentric and Exocentric views by bridging the perspective gap through 3D lifting and dual-latent (Semantic + Geometric) matching.
- **IDEA:** A multi-stage pipeline that treats objects as 3D entities to normalize viewpoint distortions:
 - **Exo-side 3D Distillation:** Use **SAM 3** on multi-view exocentric feeds to isolate 3D object segments.
 - **Semantic Labeling (CLIP/SigLIP):** Render the 3D object from multiple virtual angles. Apply **Majority Voting** on CLIP embeddings to assign a stable text label (e.g., "power drill") to the asset.
 - **Ego-side Grounding:** Use **Grounding DINO** to find the "power drill" in the Ego-view, then use **FastSAM** for a sharp instance mask.
 - **Geometric Verification (DINOv2):** Lift the Ego-candidate to 3D using **SAM 3**.
 - Compare the **DINOv2 features** of the Ego-3D asset against the Exo-3D asset.
 - **Final Matching:** Perform **Cosine Similarity** on the DINOv2 descriptors.
- **SOURCES:**
 - <https://arxiv.org/abs/2506.06026>
 - <https://ai.meta.com/research/sam3d/>
 - <https://arxiv.org/abs/2303.05499>

Source view (Ego)




Destination view (Exo)



Proposal#11: SE(3)-Clifford Implicit Convolutional Kernels.

- **GOAL:** This project develops a **Geometric Algebra-driven** generative model for **E(3)-equivariant implicit kernels**, benchmarking its performance against the original paper's experiments in 3D object classification, molecular modeling, and particle physics
- **IDEA:** Replace the standard equivariant MLP in Implicit Kernel architectures with the **GatR (Geometric Algebra Transformer)** to process geometric data as multivectors:
- **Implicit Kernel Core:** Instead of predicting point-wise occupancy directly, the model learns a kernel function $k(x,y)$ that represents the surface.
- **GATr Backbone:** The kernel is parameterized by an **E(3)-Equivariant NN**. Unlike standard equivariant NNs that handle only vectors, GATr operates on the **Projective Geometric Algebra**.
- **Geometric Primitives:** The model represents points, planes, and lines as multivectors.
- **SOURCES:**
 - <https://arxiv.org/pdf/2212.06096>
 - <https://arxiv.org/pdf/2305.18415>



Proposal#12: (Almost) Zero-Shot Open-Vocabulary 6D Pose Prediction via SAM3D Lifting and Equivariant Superquadric Decomposition

- **GOAL:** To design a **model-free, text-driven 6D pose estimation** framework that can localize and orient **unseen objects** in 3D space. The system aims to move beyond fixed CAD databases by using natural language to identify targets, **SAM3D** to lift them into 3D, and **Superquadrics (SQ)** as an ultra-compressed geometric representation. By processing these primitives through an **E(3)-Equivariant Clifford GCN**, the project seeks to achieve robust, symmetry-aware pose predictions that generalize across novel geometries and arbitrary spatial orientations.
- **IDEA:** The pipeline operates through four distinct stages of abstraction:
 1. **Open-Vocabulary Semantic Segmentation:** The user provides a text prompt (e.g., "*the car*"). A foundation model (such as Grounding DINO + SAM) identifies the object in the initial RGB image and generates a precise 2D mask.
 2. **3D Spatial Lifting (SAM3D):** The 2D mask is passed to **SAM3D**, which "lifts" the segmented object into 3D space.
 3. **PartGS: Multi-View Superquadric Representation:** Using the multi-view images and the 3D masks, the system employs the **PartGS** (Gaussian Splatting to Superquadrics) methodology. This step optimizes a set of 3D Gaussians constrained to fit **Superquadric primitives**. The result is a **super-compressed** 3D description: instead of millions of points or voxels, the object is now represented by a small set of parametric shapes that capture its "geometric skeleton."
 4. **E(3)-Equivariant Clifford GCN Prediction:** These superquadrics are treated as nodes in a graph and fed into a **Clifford Graph Convolutional Network**. Because the network is **E(3)-Equivariant**, it natively respects the laws of Euclidean physics. It processes the multivector representations of the SQs to predict the final **6D Pose** (Orientation and Translation) as a **Motor** in Clifford Algebra. This ensures the pose remains accurate even if the object is seen from a completely new angle or translated in the workspace.
- **SOURCES:**
 - a. <https://arxiv.org/pdf/2408.10789>
 - b. <https://arxiv.org/pdf/2305.18415>
 - c. <https://arxiv.org/pdf/2601.05573>

